

LAPORAN UJIAN AKHIR SEMESTER
MATA KULIAH KECERDASAN DATA DAN KOMPUTASI
ADAPTIF

Prediksi Risiko Putus Sekolah dan Penurunan Performa Siswa
Menggunakan Pendekatan Supervised Learning Untuk Identifikasi Dini
Siswa Berisiko



Disusun Oleh:

Muhamad Halim Pratama 25032014016

Moch. Nasrudin 25032014061

Brilian Nur Muhammad 25032014002

Bintang Sentanu Prasetyo 25032014055

S1 KECERDASAN ARTIFISIAL
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS NEGERI SURABAYA

2026

PENDAHULUAN

Angka putus sekolah dan penurunan performa akademik siswa merupakan permasalahan sistemik yang berdampak langsung terhadap pencapaian Tujuan Pembangunan Berkelanjutan (Sustainable Development Goals/SDGs), khususnya SDG 4 tentang Pendidikan Bermutu. Deteksi dini terhadap siswa yang berisiko memerlukan analisis komprehensif atas berbagai faktor akademik dan demografis yang sering kali tidak dapat diidentifikasi secara manual oleh tenaga pendidik dalam skala besar. (UNESCO, 2023)

Proyek ini membangun sebuah sistem prediksi berbasis supervised machine learning yang menganalisis nilai akademik, tingkat kehadiran, dan faktor demografi siswa untuk mengidentifikasi potensi kegagalan akademik sebelum terjadi. Sistem menggunakan lima algoritma klasifikasi, yaitu Decision Tree (DT), K-Nearest Neighbor dengan jarak Euclidean, Minkowski, Manhattan, dan Hamming, yang diuji pada dataset Student Performance UCI untuk mata pelajaran Matematika (student-mat.csv) dan Bahasa Portugis (student-por.csv). (Cortez & Silva, 2008)

Pemilihan kombinasi algoritma ini didasari oleh kebutuhan untuk membandingkan pendekatan berbasis aturan (Decision Tree) dengan pendekatan berbasis kemiripan instans (KNN) menggunakan metrik jarak yang beragam, sehingga dapat diidentifikasi model yang paling sesuai untuk karakteristik data performa siswa.

1.1 Tujuan Sistem

- a. Memprediksi risiko kegagalan akademik siswa ($G3 < 10$) secara otomatis berdasarkan fitur akademik dan demografis.
- b. Membandingkan akurasi lima model klasifikasi: Decision Tree, KNN Euclidean, KNN Minkowski, KNN Manhattan, dan KNN Hamming.
- c. Memberikan dasar analitik bagi sekolah untuk mengalokasikan intervensi bimbingan konseling secara proaktif dan tepat sasaran.
- d. Menyelaraskan solusi teknologi dengan target SDG 4 Pendidikan Bermutu.

1.2 Keterkaitan dengan SDG 4

Sistem ini secara langsung mendukung SDG 4.1 yang mengamanatkan pendidikan dasar dan menengah yang bermutu, inklusif, dan merata, serta target 4.5 yang berfokus pada penghapusan kesenjangan gender dan jaminan akses pendidikan bagi kelompok rentan. Dengan mengidentifikasi siswa berisiko secara dini, sekolah dapat mengalokasikan sumber daya intervensi seperti bimbingan konseling, program remedial, dan perhatian orang tua secara lebih efektif sebelum siswa tertinggal terlalu jauh. (Sachs et al., 2022)

KONSEP AI DAN ANALISIS SWOT

2.1 Konsep AI Dasar: Supervised Learning untuk Klasifikasi

Sistem ini menggunakan paradigma Supervised Learning, di mana model dilatih menggunakan dataset berlabel untuk mempelajari pola hubungan antara fitur input (usia, waktu belajar, jumlah kegagalan, absensi, nilai semester 1 dan 2) dan label output (lulus/tidak lulus berdasarkan nilai akhir G3). Proses pelatihan mengoptimalkan parameter model agar prediksi pada data baru (data uji) memiliki akurasi setinggi mungkin. (Mitchell, 1997; Bishop, 2006)

Dua keluarga algoritma yang digunakan dalam sistem ini adalah:

a. Decision Tree (DT)

Decision Tree membangun model berupa pohon keputusan di mana setiap simpul internal merepresentasikan pengujian pada satu fitur, setiap cabang merepresentasikan hasil pengujian, dan setiap daun merepresentasikan label kelas. Algoritma ini menggunakan kriteria impurity seperti Gini Index atau Information Gain untuk menentukan fitur terbaik pada setiap pembelahan. Kelebihannya adalah interpretabilitas yang tinggi karena aturan keputusan dapat dibaca langsung dari struktur pohon. (Quinlan, 1993; Breiman et al., 1984)

b. K-Nearest Neighbor (KNN)

KNN adalah algoritma lazy learning yang mengklasifikasikan instans baru berdasarkan mayoritas label dari k tetangga terdekatnya dalam ruang fitur. Tidak ada fase pelatihan eksplisit; seluruh dataset disimpan dan digunakan saat prediksi. Perbedaan utama antar

varian KNN yang digunakan terletak pada metrik jarak yang digunakan untuk mengukur kemiripan antar instans. (Cover & Hart, 1967; Duda et al., 2000)

2.2 Metrik Jarak KNN

Keempat varian KNN yang diimplementasikan menggunakan metrik jarak berbeda:

Varian	Formula	Karakteristik
Euclidean	$d = \sqrt{\sum (x_i - y_i)^2}$	Jarak garis lurus dalam ruang fitur; sensitif terhadap skala fitur
Minkowski (p=2)	$d = (\sum x_i - y_i ^p)^{1/p}$	Generalisasi Euclidean dan Manhattan; identik dengan Euclidean saat p=2
Manhattan	$d = \sum x_i - y_i $	Robust terhadap outlier; cocok untuk data dengan banyak dimensi
Hamming	$d = \sum (x_i \neq y_i) / n$	Menghitung proporsi fitur yang berbeda nilainya; umumnya untuk data nominal

Catatan: Penggunaan Hamming distance pada data numerik kontinyu (seperti nilai akademik) menghasilkan akurasi lebih rendah karena metrik ini dirancang untuk data kategorikal atau biner. Ini menjelaskan akurasi Hamming yang lebih rendah dibandingkan varian lain.

2.3 Analisis SWOT Sistem

Dimensi	Uraian
Strengths (Kekuatan)	Deteksi dini berbasis data memungkinkan sekolah dan guru mengalokasikan sumber daya intervensi (bimbingan konseling, remedial, perhatian wali kelas) secara proaktif dan tepat sasaran sebelum siswa benar-benar tertinggal. Model Decision Tree menghasilkan aturan yang dapat dijelaskan kepada guru secara intuitif tanpa latar belakang teknis.

Weaknesses (Kelemahan)	Model tidak dapat menangkap faktor emosional dan psikologis siswa yang berubah mendadak di luar riwayat data historis, seperti krisis keluarga akut, bullying, atau gangguan kesehatan mental tiba-tiba. Prediksi sepenuhnya bergantung pada kualitas dan kelengkapan data input yang dilaporkan sekolah.
Opportunities (Peluang)	Sistem dapat dikembangkan menjadi platform Personalized Learning yang menyesuaikan materi dan kecepatan kurikulum berdasarkan profil belajar individu. Integrasi dengan sistem informasi sekolah (SIMS) memungkinkan monitoring real-time dan intervensi otomatis.
Threats (Ancaman)	Risiko stigmatisasi: guru dapat secara tidak sadar memperlakukan siswa yang dilabeli 'akan gagal' dengan ekspektasi lebih rendah (efek Pygmalion negatif), justru memperburuk performa. Penyalahgunaan data prediksi juga dapat menimbulkan isu privasi dan diskriminasi algoritmik jika tidak diatur dengan kebijakan yang ketat.

DATASET DAN PERSIAPAN DATA

3.1 Sumber Dataset

Dataset yang digunakan adalah Student Performance Dataset dari UCI Machine Learning Repository yang dikumpulkan oleh Paulo Cortez dan Alice Silva dari Universidade do Minho, Portugal. Dataset ini mencakup data performa siswa pada dua mata pelajaran di sekolah menengah Portugis. (Cortez & Silva, 2008)

Properti	student-mat.csv	student-por.csv	Gabungan
Jumlah Instans	395 siswa	649 siswa	1.044 siswa
Jumlah Fitur Asli	33 fitur	33 fitur	33 fitur
Mata Pelajaran	Matematika	Bahasa Portugis	-
Lulus ($G3 \geq 10$)	67.8%	84.1%	78.0% (814 siswa)
Tidak Lulus ($G3 < 10$)	32.2%	15.9%	22.0% (230 siswa)
Properti	student-mat.csv	student-por.csv	Gabungan
Nilai G3 Rata-rata	10.41	11.91	11.34

3.2 Fitur yang Digunakan

Dari 33 fitur asli, dipilih 6 fitur yang paling relevan dan memiliki korelasi signifikan dengan performa akhir siswa (G3). Pemilihan fitur ini didasarkan pada pertimbangan ketersediaan data historis yang mudah diperoleh sekolah:

Nama Fitur	Tipe	Deskripsi
age	Numerik	Usia siswa (15–22 tahun)
studytime	Ordinal (1-4)	Waktu belajar mingguan (1:<2j, 2:2-5j, 3:5-10j, 4:>10j)
failures	Numerik (0-4)	Jumlah kegagalan kelas sebelumnya
absences	Numerik (0-93)	Jumlah ketidakhadiran selama tahun ajaran
G1	Numerik (0-20)	Nilai semester pertama
G2	Numerik (0-20)	Nilai semester kedua

3.3 Definisi Label Target

Label target (y) didefinisikan sebagai variabel biner berdasarkan nilai akhir G3:

- $y = 1$ (Lulus): $G3 \geq 10$ (setara nilai 10/20 atau batas kelulusan minimum di sistem pendidikan Portugis)
- $y = 0$ (Tidak Lulus): $G3 < 10$ (berpotensi putus sekolah atau memerlukan intervensi)

Khusus untuk KNN Hamming (knn_hamming.py), label diperluas menjadi tiga kelas risiko: TINGGI ($G3 < 10$), SEDANG ($10 \leq G3 < 15$), dan RENDAH ($G3 \geq 15$), sehingga sistem dapat memberikan gradasi prioritas intervensi yang lebih spesifik.

3.4 Pembagian Data dan Preprocessing

Seluruh model menggunakan pembagian train-test split 80:20 dengan random_state=42 untuk memastikan reproduktifitas hasil. Model KNN Manhattan mengimplementasikan normalisasi Min-Max secara manual sebelum penghitungan jarak, sedangkan model lainnya menggunakan data mentah karena Decision Tree dan KNN Scikit-learn dengan metrik tertentu bersifat skala-agnostik atau memiliki normalisasi internal.

KODE PROGRAM

4.1 Decision Tree (dt_simple.py)

Model Decision Tree diimplementasikan menggunakan scikit-learn dengan kedalaman maksimum 3 (max_depth=3) untuk mencegah overfitting sekaligus mempertahankan interpretabilitas:

```
import pandas as pd
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score

mat = pd.read_csv('student-mat.csv', sep=';')
por = pd.read_csv('student-por.csv', sep=';')
df = pd.concat([mat, por], ignore_index=True)

X = df[['age', 'studytime', 'failures', 'absences', 'G1', 'G2']]
y = (df['G3'] >= 10).astype(int) # 1=Lulus, 0=Tidak Lulus

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)

model = DecisionTreeClassifier(max_depth=3, random_state=42)
model.fit(X_train, y_train)
print(f"Akurasi: {accuracy_score(y_test,
model.predict(X_test)):.2%}")
```

4.2 KNN Euclidean (Knn_Student.py)

KNN Euclidean menggunakan seluruh 33 fitur dataset student-mat.csv dengan encoding otomatis untuk fitur kategorikal:

```

from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, classification_report

# Encode semua kolom kategorikal
for column in df.columns:    if
df[column].dtype == object:
    df[column], _ = pd.factorize(df[column])

knn = KNeighborsClassifier(n_neighbors=5, metric='euclidean')
knn.fit(X_train, y_train)
print(f"Accuracy: {accuracy_score(y_test, y_pred):.4f}")

```

4.3 KNN Minkowski (knn_minkowski.py)

KNN Minkowski menggunakan parameter $p=2$ (identik dengan Euclidean) namun hanya pada 6 fitur terpilih dari dataset gabungan:

```

model = KNeighborsClassifier(n_neighbors=5, metric='minkowski', p=2)
model.fit(X_train, y_train) y_pred = model.predict(X_test)
print(f"Akurasi: {accuracy_score(y_test, y_pred):.2%}")

```

4.4 KNN Manhattan (manhattan.py)

KNN Manhattan diimplementasikan dari scratch tanpa library scikit-learn, dengan normalisasi Min-Max manual dan penghitungan jarak Manhattan eksplisit:

```

# Normalisasi Min-Max
mins = [min(X[i][j] for i in range(len(X))) for j in range(n_fitur)]
maxs = [max(X[i][j] for i in range(len(X))) for j in range(n_fitur)]
for i in range(len(X)):    for j in range(n_fitur):
    X[i][j] = (X[i][j]-mins[j])/(maxs[j]-mins[j]) if
maxs[j]>mins[j] else 0.0

def manhattan(x1, x2):    return sum(abs(a - b)
for a, b in zip(x1, x2))

```



```
def knn(X_train, y_train, x_baru, k=5):    dists =
sorted([(manhattan(x_baru,xt), yt) for xt,yt in
zip(X_train,y_train)])
    labels = [l for _, l in dists[:k]]
return 1 if sum(labels)/k >= 0.5 else 0
```

4.5 KNN Hamming (knn_hamming.py)

KNN Hamming menggunakan klasifikasi tiga kelas (TINGGI/SEDANG/RENDAH) dan implementasi custom untuk Hamming distance:

```
# Label 3 kelas risiko df['risiko'] = df['G3'].apply(    lambda x:
'TINGGI' if x<10 else ('SEDANG' if x<15 else 'RENDAH'))

def hamming_distance(a, b):    return sum(x != y for
x, y in zip(a, b)) / len(a)

def knn_hamming_predict(X_train, y_train, X_test, k=5):
prediksi = []    for test_point in X_test:
    jarak = [hamming_distance(test_point, tp) for tp in
X_train.values]    tetangga =
sorted(range(len(jarak)), key=lambda i: jarak[i])[:k]
    label_tetangga = [y_train.iloc[i] for i in tetangga]
prediksi.append(max(set(label_tetangga),
key=label_tetangga.count))    return prediksi
```

HASIL EKSPERIMEN DAN ANALISIS

5.1 Ringkasan Hasil Akurasi

Seluruh model diuji pada data uji (20% dari dataset) yang sama, menggunakan random_state=42. Berikut adalah hasil akurasi yang diperoleh:

Model	Dataset	Split	Akurasi	Keterangan
Decision Tree (max_depth=3)	Gabungan (1.044)	80:20	87.08%	6 fitur terpilih
KNN Euclidean (k=5)	student-mat.csv (395)	80:20	88.61%	33 fitur, semua digunakan
KNN Minkowski p=2 (k=5)	Gabungan (1.044)	80:20	85.65%	6 fitur terpilih
KNN Manhattan (k=5)	Gabungan (1.044)	80:20	90.43%	6 fitur + normalisasi
KNN Hamming (k=5)	Gabungan (1.044)	80:20	80.86%	3 kelas, 6 fitur

5.2 Analisis Per Model

a. Decision Tree – Akurasi 87.08%

Decision Tree dengan max_depth=3 berhasil mencapai akurasi 87.08% dengan keunggulan utama berupa interpretabilitas tinggi. Struktur pohon yang dibatasi kedalaman 3 mencegah overfitting sekaligus menghasilkan aturan yang dapat dijelaskan secara verbal kepada guru, misalnya: 'Jika $G2 < 9.5$ AND $failures \geq 0.5$, maka siswa berisiko tidak lulus'. Pemangkasan kedalaman ini adalah trade-off yang disengaja antara akurasi dan kemudahan interpretasi untuk konteks pendidikan. (Quinlan, 1993)

b. KNN Euclidean – Akurasi 88.61%

KNN Euclidean mencapai 88.61% menggunakan seluruh 33 fitur dari dataset studentmat.csv (395 siswa). Keunggulan menggunakan semua fitur adalah informasi demografis seperti pendidikan orang tua, aktivitas ekstrakurikuler, dan dukungan keluarga turut dipertimbangkan dalam prediksi. Namun, penggunaan data hanya dari satu mata pelajaran (Matematika) dan tidak adanya normalisasi fitur menjadi catatan yang perlu diperhatikan untuk generalisasi.

c. KNN Minkowski (p=2) – Akurasi 85.65%

KNN Minkowski dengan p=2 secara matematis identik dengan KNN Euclidean, namun menghasilkan akurasi lebih rendah (85.65%) karena menggunakan dataset gabungan (1.044 siswa) dengan hanya 6 fitur dibandingkan 33 fitur pada KNN Euclidean. Perbedaan akurasi ini bukan karena inferioritas metrik Minkowski, melainkan karena perbedaan dataset dan

jumlah fitur yang digunakan. Hasil ini tetap valid sebagai perbandingan dalam konteks 6 fitur terpilih.

d. KNN Manhattan – Akurasi 90.43% (Tertinggi)

KNN Manhattan mencapai akurasi tertinggi di antara semua model yang diuji (90.43%) pada dataset gabungan dengan 6 fitur. Keunggulan ini dapat dijelaskan oleh dua faktor: (1) normalisasi Min-Max yang diterapkan sebelum penghitungan jarak menghilangkan efek perbedaan skala antar fitur (misalnya absensi 0-93 vs studytime 1-4); dan (2) jarak Manhattan lebih robust terhadap outlier dalam data absensi siswa dibandingkan Euclidean karena tidak mengkuadratkan selisih. (Aha et al., 1991)

e. KNN Hamming – Akurasi 80.86%

KNN Hamming menghasilkan akurasi terendah (80.86%), yang dapat dijelaskan oleh ketidaksesuaian metrik dengan tipe data. Hamming distance dirancang untuk data kategorikal atau biner, di mana dua nilai dianggap 'sama' atau 'berbeda' tanpa mempertimbangkan besarnya selisih numerik. Pada data akademik kontinyu seperti nilai $G1=15$ vs $G1=16$ dianggap sama berbedanya dengan $G1=5$ vs $G1=16$, yang secara semantik tidak tepat. Meskipun demikian, model ini memberikan keunggulan berupa klasifikasi tiga kelas risiko (TINGGI/SEDANG/RENDAH) yang lebih granular untuk tujuan intervensi.

5.3 Distribusi Risiko Siswa (KNN Hamming)

Berdasarkan prediksi KNN Hamming pada seluruh dataset (1.044 siswa):

Kategori Risiko	Jumlah Siswa	Persentase	Implikasi Intervensi
TINGGI ($G3 < 10$)	199 siswa	19.1%	Prioritas utama: bimbingan intensif
SEDANG ($10 \leq G3 < 15$)	670 siswa	64.2%	Pemantauan berkala dan dukungan
RENDAH ($G3 \geq 15$)	175 siswa	16.8%	Program pengayaan/akselerasi

DISKUSI

6.1 Perbandingan Komparatif Algoritma

Berdasarkan hasil eksperimen, terdapat beberapa temuan penting yang perlu didiskusikan:

- a. KNN Manhattan dengan normalisasi adalah model terbaik untuk dataset gabungan 6 fitur, dengan akurasi 90.43%. Normalisasi Min-Max terbukti meningkatkan performa secara signifikan karena menghilangkan dominasi fitur berskala besar seperti absences terhadap perhitungan jarak.
- b. Decision Tree menawarkan trade-off terbaik antara akurasi dan interpretabilitas. Dengan akurasi 87.08% dan struktur aturan yang dapat dijelaskan, model ini paling cocok untuk deployment di lingkungan sekolah di mana kepercayaan guru terhadap sistem sangat penting.
- c. Perbedaan akurasi antara KNN Euclidean (88.61%) dan KNN Minkowski (85.65%) bukan disebabkan perbedaan metrik, melainkan perbedaan jumlah fitur (33 vs 6) dan ukuran dataset (395 vs 1.044). Perbandingan yang adil memerlukan kondisi eksperimen yang identik.
- d. KNN Hamming tidak optimal untuk data numerik kontinyu, namun skema labelisasi tiga kelasnya memberikan nilai tambah praktis untuk triase intervensi di lapangan.

6.2 Keterbatasan dan Ancaman Validitas

Beberapa keterbatasan yang perlu diakui dalam analisis ini adalah:

- a. Konteks dataset terbatas pada sekolah menengah Portugis; generalisasi ke konteks pendidikan Indonesia memerlukan validasi ulang dengan data lokal.
- b. Kondisi eksperimen antar model tidak sepenuhnya identik (beda jumlah fitur, beda subset dataset), sehingga perbandingan akurasi lintas model harus diinterpretasikan dengan hati-hati.
- c. Metrik evaluasi hanya menggunakan akurasi keseluruhan; pada dataset yang tidak seimbang (78% lulus vs 22% tidak lulus), metrik precision, recall, dan F1-score

untuk kelas minoritas (tidak lulus) lebih informatif. KNN Euclidean melaporkan F1-score 0.83 untuk kelas tidak lulus dan 0.91 untuk kelas lulus.

- d. Model tidak mencakup fitur dinamis seperti perubahan nilai antar semester yang dapat menjadi sinyal peringatan dini yang lebih kuat.

6.3 Risiko Stigmatisasi dan Etika Algoritma

Implementasi sistem prediksi berbasis AI di lingkungan sekolah membawa risiko etis yang tidak boleh diabaikan. Penelitian dalam psikologi pendidikan menunjukkan bahwa ekspektasi guru terhadap siswa secara signifikan mempengaruhi performa aktual siswa (Rosenthal & Jacobson, 1968). Label 'berisiko gagal' dari sistem AI berpotensi menciptakan self-fulfilling prophecy negatif jika tidak dikelola dengan tepat.

Rekomendasi mitigasi risiko etis meliputi: (1) output sistem hanya diakses oleh konselor dan kepala sekolah, bukan seluruh guru; (2) prediksi dikomunikasikan sebagai 'memerlukan perhatian ekstra' bukan 'akan gagal'; (3) sistem secara eksplisit melarang penggunaan label prediksi untuk keputusan promosi atau seleksi; dan (4) audit berkala terhadap bias algoritmik berdasarkan faktor demografis. (Barocas et al., 2019)

KESIMPULAN

Berdasarkan hasil implementasi dan analisis yang telah dilakukan, beberapa kesimpulan utama dapat ditarik:

- a. KNN Manhattan dengan normalisasi Min-Max mencapai akurasi tertinggi (90.43%) pada dataset gabungan 6 fitur, membuktikan bahwa preprocessing normalisasi berdampak signifikan terhadap performa model berbasis jarak.
- b. Decision Tree (87.08%) menawarkan keseimbangan terbaik antara akurasi dan interpretabilitas, menjadikannya kandidat paling cocok untuk deployment nyata di sekolah karena aturan keputusannya dapat dikomunikasikan kepada guru nonteknis.
- c. KNN Hamming (80.86%) menghasilkan akurasi terendah akibat ketidaksesuaian metrik dengan data numerik, namun skema tiga kelas risikonya (TINGGI: 19.1%,

SEDANG: 64.2%, RENDAH: 16.8%) memberikan granularitas triase intervensi yang bernilai praktis.

- d. Nilai akademik sebelumnya (G1 dan G2) konsisten menjadi prediktor terkuat kelulusan G3 di semua model, diikuti oleh failures, yang menunjukkan bahwa intervensi dini setelah semester pertama memiliki dampak paling besar.
- e. Sistem ini secara langsung mendukung SDG 4.1 dan 4.5 dengan memungkinkan alokasi sumber daya intervensi yang lebih efisien dan berbasis bukti.

REFERENSI

- Aha, D. W., Kibler, D., & Albert, M. K. (1991). Instance-based learning algorithms. *Machine Learning*, 6(1), 37–66.
- Barocas, S., Hardt, M., & Narayanan, A. (2019). *Fairness and Machine Learning: Limitations and Opportunities*. fairmlbook.org.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Breiman, L., Friedman, J., Stone, C. J., & Olshen, R. A. (1984). *Classification and Regression Trees*. Wadsworth & Brooks.
- Cortez, P., & Silva, A. (2008). Using data mining to predict secondary school student performance. In *Proceedings of 5th Future Business Technology Conference* (pp. 5–12). EUROSIS. <https://doi.org/10.1145/n/a>
- Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1), 21–27.
- Duda, R. O., Hart, P. E., & Stork, D. G. (2000). *Pattern Classification* (2nd ed.). WileyInterscience.
- Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill.
- Quinlan, J. R. (1993). *C4.5: Programs for Machine Learning*. Morgan Kaufmann.
- Rosenthal, R., & Jacobson, L. (1968). *Pygmalion in the Classroom: Teacher Expectation and Pupils' Intellectual Development*. Holt, Rinehart and Winston.
- Sachs, J. D., Lafortune, G., Fuller, G., & Drumm, E. (2022). *Sustainable Development Report 2022*. Cambridge University Press.

UNESCO. (2023). Global Education Monitoring Report 2023: Technology in education –
A tool on whose terms? UNESCO Publishing.